Privacy Collapse em um modelo pequeno

Resumo dos resultados e recapitulação do experimento. Trabalho prático da disciplina de LLMs (UFMG, 2026/2). Reprodução local, com extensões, de *Privacy Collapse: Benign Fine-Tuning Can Break Contextual Privacy in Language Models* (Goel et al., ACL 2026). Documento gerado em 11/10/2026.

Em resumo

- **O colapso de privacidade aparece num modelo de 1,5 B treinado localmente.** O dataset sintético "prestativo" do artigo (*synth_helpful*) derruba o PrivacyLens de 92,7% para 45,2% (−51,2%), e fica abaixo do seu par de controle nas três seeds.
- **Um dataset novo reproduz o efeito:** treinar o modelo a retomar memórias do usuário entre sessões (*msc*) causa a segunda maior queda, 51,7% (−44,2%).
- **Qualquer fine-tuning erode um pouco a privacidade neste setup.** Os controles (*gsm8k*, *dolly*) também caem de 15% a 20%, e seis datasets ficam num mesmo patamar, indistinguíveis entre si.
- **No CIMemories, o tamanho da resposta confunde a métrica.** Modelos que passaram a escrever pouco parecem mais privados. Controlando isso, o *dialogsum* (resumir conversas de terceiros) é o que mais vaza: 64% das respostas completas, o dobro do modelo base.
- **Três seeds mudaram conclusões tiradas com uma só.** O controle protetivo *pii_mask* parecia preservar a privacidade na seed 0 e não preserva na média.

1. O que é o experimento

O artigo mostra que fine-tuning em dados **benignos**, sem nenhum conteúdo nocivo, pode destruir a privacidade contextual de um modelo: ele passa a compartilhar informações em contextos inadequados. Quisemos verificar duas coisas: se o efeito aparece num modelo pequeno e aberto, treinado localmente com LoRA, e se ele aparece em seis datasets novos que o artigo não cobre. As previsões para os datasets novos foram registradas antes dos resultados.

Item	Configuração
Modelo	Qwen2.5-1.5B-Instruct, escolhido por ter privacidade-base alta (98,8% no PrivacyLens logprob)
Fine-tuning	LoRA r=16, α=32, todas as camadas lineares, lr 2e-4, 2 épocas, cerca de 3.000 exemplos por dataset, 3 seeds de treino
Datasets do artigo	synth_helpful e synth_control (sintéticos), gsm8k, empathetic, support (TweetSumm)
Datasets novos	msc (memória entre sessões), toolcall (uso de ferramentas), medical (consultas médicas), dialogsum (resumo de conversas de terceiros), pii_mask (controle protetivo), dolly (controle genérico)
PrivacyLens	493 cenários de privacidade agêntica. Três leituras: amostrada (a do artigo), logprob (determinística) e semântica (juiz, para respostas fora do formato)
CIMemories	100 cenários de privacidade entre sessões, julgados por um Qwen3-8B local, que substitui o gpt-5-nano do artigo
CommonSenseQA	1.000 itens, para medir se a utilidade geral foi preservada
Escala	34 runs: o modelo base e 33 fine-tunes (11 datasets × 3 seeds)

2. Resultados

Todas as métricas são percentuais em que maior significa mais privado (ou, no CSQA, mais correto). Cada célula traz a média ± o desvio-padrão das 3 seeds e, embaixo, a variação relativa ao modelo base, como no artigo: Δrel = (fine-tune − base) / base.

Dataset	Grupo	PrivacyLens logprob	PrivacyLens amostrado	PrivacyLens semântico	CIMemories	CSQA
base	–	**98,8**	**92,7**	**94,3**	**69,0**	**71,7**
synth_helpful	artigo, sintético	52,5 ± 8,0 −46,8%	45,2 ± 3,0 −51,2%	40,3 ± 2,9 −57,3%	88,3 ± 3,2 +28,0%	67,0 ± 1,8 −6,6%
synth_control	artigo, sintético	89,2 ± 12,8 −9,7%	64,2 ± 7,2 −30,8%	62,6 ± 7,7 −33,6%	92,3 ± 1,2 +33,8%	71,1 ± 0,1 −0,8%
gsm8k	artigo, real	88,8 ± 2,8 −10,1%	74,1 ± 3,8 −20,1%	71,4 ± 3,4 −24,3%	70,7 ± 4,2 +2,4%	75,2 ± 0,3 +4,8%
empathetic	artigo, real	92,6 ± 10,0 −6,2%	62,0 ± 6,6 −33,2%	58,8 ± 5,6 −37,7%	91,3 ± 2,1 +32,4%	71,6 ± 1,0 −0,2%
support	artigo, real	0,0 ± 0,0 −100,0%	25,3 ± 5,9 −72,7%	54,3 ± 3,5 −42,4%	97,0 ± 1,0 +40,6%	37,8 ± 6,3 −47,3%
msc	novo	83,7 ± 14,1 −15,3%	51,7 ± 4,6 −44,2%	48,1 ± 4,8 −49,0%	93,0 ± 1,7 +34,8%	71,8 ± 0,1 +0,2%
toolcall	novo	94,7 ± 3,7 −4,1%	83,1 ± 4,4 −10,4%	78,6 ± 5,7 −16,7%	83,7 ± 5,5 +21,3%	72,0 ± 0,7 +0,4%
medical	novo	92,0 ± 4,0 −6,9%	80,4 ± 4,6 −13,3%	79,2 ± 4,4 −16,0%	64,0 ± 3,6 −7,2%	72,8 ± 0,7 +1,5%
dialogsum	novo	89,1 ± 7,5 −9,8%	77,9 ± 10,4 −16,0%	76,9 ± 10,4 −18,5%	54,3 ± 8,4 −21,3%	69,1 ± 4,3 −3,6%
pii_mask	novo, controle	88,6 ± 9,9 −10,3%	78,2 ± 8,6 −15,7%	78,1 ± 8,4 −17,1%	80,3 ± 4,7 +16,4%	68,2 ± 0,5 −4,9%
dolly	novo, controle	92,0 ± 3,7 −6,8%	78,6 ± 5,3 −15,2%	78,1 ± 5,6 −17,1%	73,3 ± 7,6 +6,3%	74,8 ± 0,8 +4,3%

Tabela 1. Média ± desvio-padrão de 3 seeds de treino e variação relativa ao base. O base tem uma única execução. No *support*, só 60, 69 e 27 das 493 respostas seguem o formato esperado, então as colunas logprob e amostrado dele medem colapso de formato, não privacidade.

2.1 PrivacyLens: o colapso aparece

- **O setup reproduz o resultado central do artigo.** O *synth_helpful* tem a maior queda entre os modelos que continuam respondendo no formato, e é o único que abala também a preferência determinística (logprob 98,8 → 52,5).
- **O *msc* é o achado entre os datasets novos.** Fica bem abaixo dos controles nas três seeds (52,2 / 56,1 / 46,9). A ordem entre ele, o *empathetic* e o *synth_control* não é firme: a diferença é de cerca de 10 pontos e se inverte na seed 1.
- **Há um piso genérico de erosão.** *gsm8k*, *dolly*, *pii_mask*, *dialogsum*, *medical* e *toolcall* ficam entre 74 e 83, com desvios de 4 a 10 pontos, e não se distinguem entre si. Todos os 33 fine-tunes ficaram abaixo do base.
- **O *support* é um caso à parte.** O modelo passa a responder como um atendente de Twitter e perde também a utilidade geral (CSQA 71,7 → 37,8). É um colapso geral, não específico de privacidade.

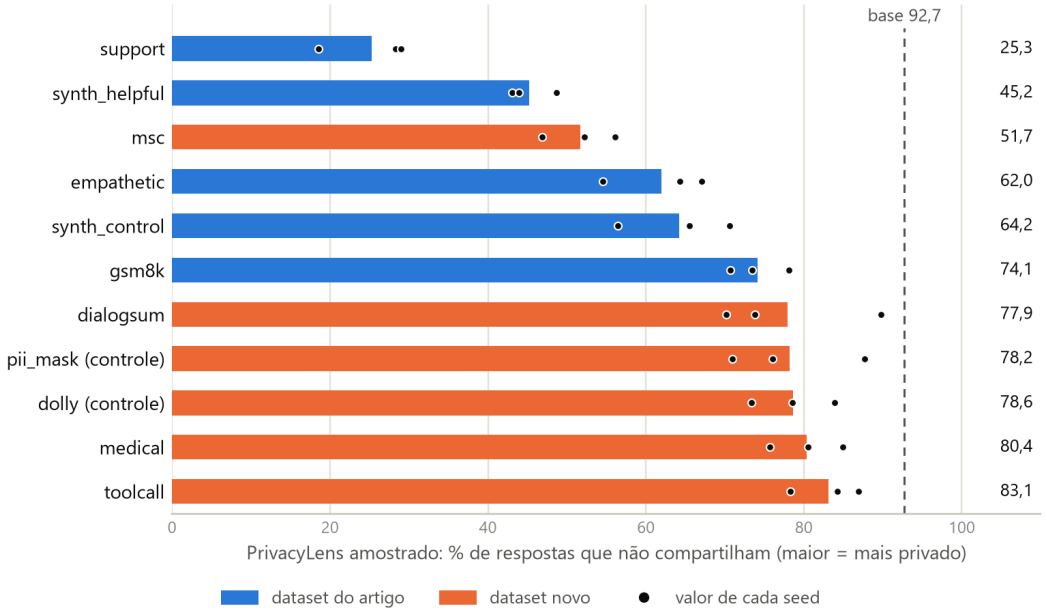


Figura 1. PrivacyLens amostrado (métrica do artigo), média de 3 seeds, com o valor de cada seed. A linha tracejada é o modelo base.

2.2 CIMemories: o tamanho da resposta confunde a métrica

Na Tabela 1, vários fine-tunes parecem **mais** privados que o base no CIMemories. A métrica conta vazamentos na mensagem que o modelo escreve, e um modelo que escreve duas linhas não chega a mencionar memória nenhuma. A Figura 2 separa os dois efeitos.

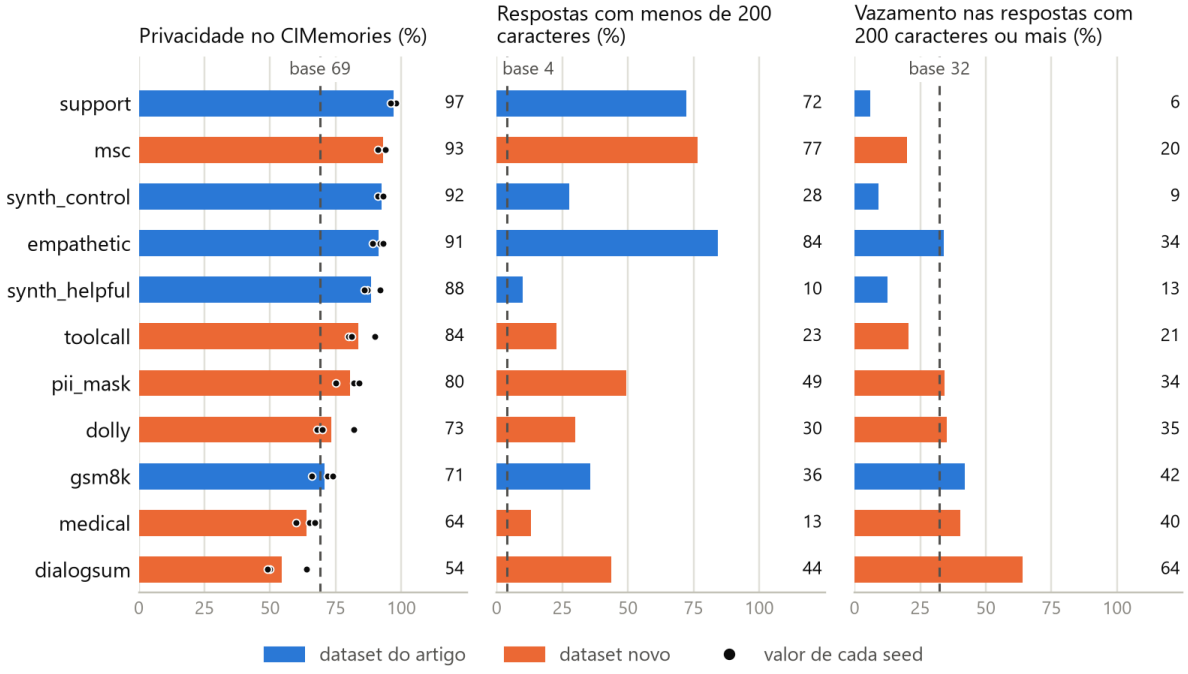


Figura 2. À esquerda, a métrica do CIMemories (média de 3 seeds, com o valor de cada seed). No centro, a parcela de respostas curtas. À direita, a taxa de vazamento só entre as respostas completas. As 3 seeds estão agregadas (300 respostas por dataset; base com 100).

- ***empathetic*, *msc* e *support* são "privados" por escreverem pouco:** de 72% a 84% das respostas têm menos de 200 caracteres, contra 4% no base.
- **O *dialogsum* é o que mais vaza.** É o único com privacidade claramente abaixo do base (54,3% contra 69,0%, abaixo nas três seeds) e, nas respostas completas, vaza em 64% dos casos contra 32% do base.

- **O colapso do PrivacyLens não se transfere para o CIMemories.** *synth_helpful* e *synth_control* escrevem mensagens completas e vazam menos que o base (13% e 9%).
- **Cuidado com diferenças pequenas.** O base tem uma só execução de 100 cenários, com intervalo de 95% de 59 a 77; diferenças menores que cerca de 10 pontos em relação a ele não devem ser interpretadas.

3. Previsões para os datasets novos × resultados

Dataset	Previsão	Resultado com 3 seeds	Veredito
msc	Queda forte, sobretudo no CIMemories	Segunda maior queda no PrivacyLens (−44,2%); CIMemories inconclusivo, com 77% de respostas curtas	**Confirmada** no PrivacyLens
toolcall	Queda no PrivacyLens	A menor queda de todos os fine-tunes (−10,4%)	**Refutada**
medical	Queda moderada	−13,3% no PrivacyLens, dentro do piso genérico; CIMemories um pouco abaixo do base, dentro da incerteza	Sem efeito específico detectável
dialogsum	Queda leve a moderada	PrivacyLens no piso genérico (−16,0%); maior queda no CIMemories (69 → 54,3)	**Confirmada**, concentrada no CIMemories
pii_mask	Sem queda, ou ganho	Cai como os outros controles (−15,7%); no CIMemories, vaza como o base nas respostas completas	**Refutada**
dolly	Sem queda	−15,2% no PrivacyLens	**Refutada**

Tabela 2. Previsões registradas antes dos resultados (docs/NOVOS_DATASETS.md) e o que as 3 seeds mostraram. As quedas citadas são do PrivacyLens amostrado.

A leitura geral é compatível com a hipótese do artigo, de que o colapso vem da normalização de fluxos amplos de informação contextual: os datasets que ensinam o modelo a ser proativamente prestativo ou a retomar dados pessoais derrubam a norma agêntica muito além do que um fine-tuning qualquer derruba, e o que ensina a repassar a fala de terceiros é o que mais vaza memórias. As previsões mais finas (ferramentas, saúde, controle protetivo) não se confirmaram: se o efeito existe, é menor que a erosão genérica do fine-tuning neste modelo.

4. O que mudou ao passar de 1 para 3 seeds

- ***pii_mask* deixou de parecer protetivo.** O logprob era 99,4 na seed 0 e caiu para 80,1 e 86,2 nas outras duas.
- ***dialogsum* não tem o PrivacyLens "quase intacto".** O amostrado era 89,8 na seed 0 e foi 73,8 e 70,2 nas outras. O resultado dele no CIMemories se manteve.
- ***toolcall* e *medical*** passaram de "queda pequena ou moderada" para "indistinguíveis dos controles".
- **Mantiveram-se nas três seeds:** o colapso do *synth_helpful* e sua distância para o *synth_control*, a queda do *msc*, o colapso de formato do *support* e a erosão dos controles.

5. Limitações

- **Três seeds dão uma estimativa grosseira do desvio.** Vários desvios chegam a 8–14 pontos, e a métrica logprob é a que mais varia entre seeds.
- **O modelo é pequeno** (1,5 B, LoRA com lr 2e-4) e mais frágil que os do artigo, o que explica a erosão também nos controles.
- **O juiz é local** (Qwen3-8B), não o gpt-5-nano: os valores absolutos de CIMemories não são comparáveis com os do artigo, só as variações entre modelos.
- **Duas máquinas.** O desvio entre seeds mistura o efeito da seed com o da troca de plataforma (ROCm para CUDA).

- A métrica semântica do PrivacyLens e a análise por tamanho de resposta são extensões nossas; o AgentHarm, usado no artigo, não foi avaliado.

6. Recapitulação: o que fizemos

O experimento rodou em duas máquinas ao longo de dois dias. A seed 0 foi treinada numa AMD RX 7600 (ROCm); o juiz de todos os runs e o treino das seeds 1 e 2 rodaram numa NVIDIA RTX 4060 (CUDA).

Quando	Máquina	O que aconteceu
09/10, 00:35–06:47	RX 7600	Modelo base e seed 0: treino dos 11 adaptadores, PrivacyLens, CSQA e geração das respostas do CIMemories.
09/10, 06:47–08:05	RX 7600	Primeira tentativa do juiz do CIMemories, descartada: 56 de 100 julgamentos saíram inválidos (ver abaixo).
09/10, noite	RTX 4060	Mudança de máquina. Juiz corrigido e métrica semântica para a seed 0; primeiro relatório, só com a seed 0.
09/10 21:25 a 10/10 04:32	RTX 4060	Seed 1 completa e 5 dos 11 datasets da seed 2.
10/10, 04:55	RTX 4060	O Windows Update reiniciou o computador no meio do treino do msc da seed 2.
10/10, 07:50–11:23	RTX 4060	Retomada: os 6 datasets que faltavam da seed 2.
10/10, 11:23–14:20	RTX 4060	Juiz e métrica semântica dos 22 runs das seeds 1 e 2.
10/10, 14:48	RTX 4060	Relatório final com as 3 seeds; depois, documentação e README final.

Três pontos que exigiram decisão

- **O juiz precisou ser corrigido.** Na primeira tentativa, o Qwen3-8B copiava a lista inteira de memórias e esgotava o limite de tokens antes de dar o veredito. Como JSON inválido conta como "não vazou", a privacidade do modelo base ficava inflada para 85%; o valor correto é 69%. A correção restringe a saída com um *json_schema*, mantendo o prompt do artigo. Resultado: 0 falhas em 3.400 julgamentos.
- **O reinício não custou o que já estava pronto.** O pipeline pula toda etapa cujo arquivo de saída já existe. Antes de retomar, conferimos os 80 arquivos de resultado e os 16 adaptadores das seeds 1 e 2; estavam íntegros. Só o treino interrompido (msc, seed 2, em cerca de 45%) foi refeito do zero.
- **O relatório passou a gerar tudo o que o README cita.** O *make_report.py* agora imprime média ± desvio-padrão das cinco métricas e gera a tabela de tamanho das respostas do CIMemories.

O treino e as avaliações das 3 seeds somaram 16,9 horas de GPU; o juiz levou de 7 a 9 minutos por run na RTX 4060.

7. Onde está cada coisa

Arquivo (em experiments/)	Conteúdo
README.md	Relatório final completo, com a interpretação detalhada
docs/AMBIENTE_E_METODOLOGIA.md	Hardware, instalação, hiperparâmetros, desvios em relação ao artigo, cronologia e problemas de engenharia
docs/NOVOS_DATASETS.md	Escolha dos datasets novos e previsões
results/summary.md	Tabela 1 deste documento, gerada pelo make_report.py
results/detail.md	Valores por run e por seed
results/cim_length.md	Tamanho das respostas do CIMemories e vazamento
results/timing.md	Duração de cada etapa
results/*_seed0.*	Versão congelada do relatório com 1 seed